

Euphonium：拡散モデルの自己回転尤度比による分布外検知

表 紘太朗[1,a)]　水谷 伸[2]　尾崎 慶次郎[3]

概要

拡散モデルの尤度は単純な分布外画像に高い値をとり, 分布外検知に失敗する (尤度パラドックス). 提案手法 Euphonium は, 画像と回転画像の尤度の比 (自己回転尤度比) を検知に用いる. 回転は複雑さを変えないため比では複雑さが消え,「正立のほうがもっともらしいか」という知識だけが残る. これは正立と回転を見分けるベイズ最適分類器の対数オッズであり, 回転予測による手がかりを追加学習なしに密度から得る. 推定では同じノイズを回転して両方に加え, 予測誤差の差を足す (共有ノイズ推定). 検知は, 90° 回転の 2 つのスケールと 180° 回転の 1 つのスケールでの誤差の対数比を足す, 1 枚 10 回の順伝播のスコア Eu で行う. 推定量と厳密な比の順位相関は 0.61–0.92 だが, Eu 自体は 0.35–0.78 で, 別の重みづけの統計量である. CIFAR-10 を分布内とする 9 集合の平均 AUROC は尤度の 57.0%, 比較手法の最良 75.0%に対し Eu は 91.2%である.

1. はじめに

分布外の入力を見分けることは, 機械学習モデルを安全に運用するための基本的な課題である. 生成モデルは画像の確率密度 $p(\vec{x})$ を学習するので, 尤度の低い画像を分布外とみなせばラベルなしで検知できるはずであり, 拡散モデル [1], [2] では確率フロー常微分方程式 (PF-ODE) で対数尤度を計算できる.

ところが深層生成モデルは, 分布外の画像に分布内より高い尤度を与えることがあり [3], 尤度パラドックスと呼ばれる. CIFAR-10(一般物体の写真) のモデルは SVHN(番地の数字) により高い尤度を与え, 本研究の再現でも尤度による SVHN の検知の AUROC は 12.5%であった (チャンスレベルは 50%). 主な原因は画像の複雑さである [4]：対数尤度は符号長に負号をつけたものなので, 平坦で単純な画像ほど高くなる.

本研究は, 回転した画像そのものを参照に用いる. 回転しても画素の値の集まりも隣り合う画素の関係も変わらないため, 画像と回転画像の複雑さはほぼ等しく, 両者の尤度の比では複雑さが打ち消されて「正立のほうがもっともらしいか」というモデルの知識だけが残る. この手がかり自体は, 回転を当てる分類器を学習して用いる分布外検知 [5], [6], [7] と同じであり, 新しいのは, それを追加学習なしで密度から取り出すことと, 同じノイズに対する二乗誤差の差 (尤度比の被積分関数) として推定することである. 本稿では, (1) 自己回転尤度比の定義, 複雑さの打ち消し, ベイズ最適な回転予測器の対数オッズとしての意味, 平均の符号を決める恒等式 (3.1 節), (2) 比を画像と回転画像のノイズ予測誤差の差の積分として書き, 両者に同じノイズを回転して加える推定法 (共有ノイズ推定) と, 1 枚 10 回の順伝播のスコア Euphonium(3.2, 3.3 節), (3) 推定量と Euphonium の厳密な比との照合, 8 つの比較手法と符号を捨てた統計量との比較, 6 つの分布内での一般性と限界 (4 節) を報告する.

[1] 慶應義塾大学 総合政策学部 3 年
[2] NTT コミュニケーション科学研究所
[3] 慶應義塾大学院 政策・メディア研究科 1 年
[a)] kotaro3150@keio.jp

表 1 先行研究と本研究の立ち位置 (文献は本文). 測る量：検知に用いる統計量. 符号：統計量が「どちらの向き (条件) がもっともらしいか」の向きをもつか (もたない量は「大きいほど分布外」と読む). ただし符号の有無そのものの寄与は小さく (4 節の表 3), GEPC との違いは測る量 (同じノイズに対する誤差の差か, 予測差のノルムか) にある.

手法	測る量	符号	学習
IC, TT	尤度の補正 (符号長, 典型性)	なし	不要
MSMA, DiffPath, EigenScore	拡散モデルの統計量の大きさ (分布内で較正)	なし	不要
GEPC	変換した入力との予測差のノルム (分布内で較正)	なし	不要
回転予測	回転予測の分類器の確信度	あり	分類器
拡散分類器	条件間の予測誤差の差 (同じノイズ)	あり	条件つきモデル
本研究	回転画像との尤度比：同じノイズに対する誤差の差 (10 回の順伝播)	あり	不要

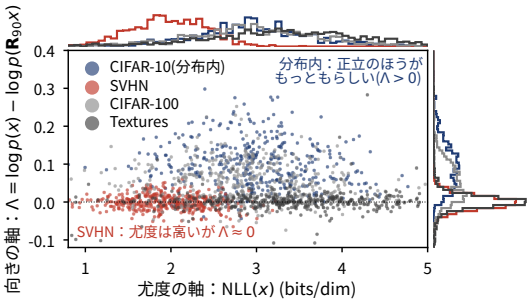


図 1 尤度は複雑さに支配され, 回転画像との比は向きに支配される (CIFAR-10 の拡散モデル, PF-ODE による尤度). 横軸は負の対数尤度 (NLL, bits/dim), 縦軸は $\Lambda = \log p(\vec{x}) - \log p(\mathbf{R}_{90}\vec{x})$.

2. 先行研究と本研究の立ち位置

尤度の補正. 尤度パラドックスへの対策として, モデルの符号長から PNG などの汎用圧縮器の符号長を差し引く入力複雑さの補正 (IC) [4] や, 尤度がモデル自身の典型集合から外れた入力を分布外とみなす典型性検定 (TT) [8] がある.

拡散モデルの統計量. 拡散モデルに固有の量を用いる方法として, 複数のノイズの大きさでのスコアのノルムを用いる MSMA [9](本稿ではそのマハラノビス距離を MSMA 型と呼ぶ), 軌跡の速度と曲率を用いる DiffPath [10], 事後共分散の固有値を用いる EigenScore [11], 変換に対する予測の不整合の大きさを測る GEPC [12] がある. いずれも量の大きさを測り,「どちらの向きがもっともらしいか」という符号をもたない. GEPC は回転したノイズ画像をノイズ除去器に通し, 予測を逆回転して正立の予測と比べる点で本研究と同じ構成をとるが, 予測差のノルムを「大きいほど分布外」と読む. 本研究との違いは, 符号の有無そのものより (符号の寄与は小さい. 4 節), 同じノイズに対する誤差の差 (尤度比の被積分関数) を測るか予測差のノルムを測るかにある.

回転予測と拡散分類器. 符号をもつ手がかりは, 幾何変換を当てる分類器を自己教師ありで学習し, その確信度で分布外を検知する一連の研究 [5], [6], [7] にある (表 1). 自己回転尤度比はこの手がかりの 2 クラス版のベイズ最適な対数オッズであり (3.1 節), 本研究はそれを追加学習なしに密度から取り出す. 条件ごとのノイズ予測誤差を同じノイズで比べる拡散分類器 [13], [14] も, 同じノイズで測った誤差の差をとることで差の揺らぎを下げる. 本研究は無条件のモデルで入力そのものを回転するためノイズも一緒に回転し (3.2 節), 同じノイズに対する誤差の差をとる. これが尤度比の被積分関数になる.

3. 提案手法：Euphonium

3.1 定義と複雑さの打ち消し

画像を $\vec{x} \in \mathbb{R}^D$ (D は画素値の個数), 回転を直交な置換行列 $\mathbf{T}$ とする ($\mathbf{T}\vec{x}$ は $\vec{x}$ を回した画像. $\mathbf{T}^{-1} = \mathbf{T}^{\top}$

であり, 長さを変えない：$|\mathbf{T}\vec{v}| = |\vec{v}|$). 分布内の画像の密度 (拡散モデルが学習したもの) を p とし, 自己回転尤度比を

$$\Lambda_{\mathbf{T}}(\vec{x}) = \log p(\vec{x}) - \log p(\mathbf{T}\vec{x}) \tag{1}$$

と定義する.

複雑さの打ち消し. Serrà ら [4] によれば, 対数尤度は汎用の可逆圧縮 (PNG など) による符号長 $L(\vec{x})$(ビット) を用いて

$$\log p(\vec{x}) \approx -L(\vec{x}) \log 2 + s(\vec{x}) \tag{2}$$

と分解できる ($\log 2$ はビットを自然対数の単位に直す係数). 第 1 項は「単純な画像ほど尤度が高い」という複雑さの効果そのものであり, 分布内らしさを表すのは残りの $s(\vec{x})$ である. 回転は画素値の集まりも隣り合う画素の関係も変えないので, 符号長 L をほぼ変えない. よって式 (2) を $\vec{x}$ と $\mathbf{T}\vec{x}$ について引き算すると第 1 項が消え,

$$\Lambda_{\mathbf{T}}(\vec{x}) \approx s(\vec{x}) - s(\mathbf{T}\vec{x}) \tag{3}$$

となる. 図 1 に CIFAR-10 のモデルでの実際の値を示す. 単純な SVHN の画像は尤度では CIFAR-10 の画像より分布内らしく見えるが, 回転しても尤度はほとんど変わらず $\Lambda \approx 0$ である (中央値は分布内 0.094, SVHN -0.001 bits/dim).

回転予測としての意味. 分布内の画像 $\vec{y}(\vec{y} \sim p)$ を逆向きに回した画像 $\vec{x} = \mathbf{T}^{-1}\vec{y}$ の分布を q とする. $\vec{x}$ を $\mathbf{T}$ で回せば $\vec{y} = \mathbf{T}\vec{x}$ に戻り, 回転は体積を変えない ($|\det \mathbf{T}| = 1$) ので

$$q(\vec{x}) = p(\mathbf{T}\vec{x}) \tag{4}$$

である. いま「正立 ($\vec{x} \sim p$) か回転 ($\vec{x} \sim q$) か」を当てる 2 クラス問題を考え, 2 つのクラスが同じ確率 1/2 で現れるとする. 画像 $\vec{x}$ を見たとき, 正立である確率と回転である確率の比 (事後オッズ) はベイズの定理より

$$\begin{aligned} \frac{P(\text{正立} \mid \vec{x})}{P(\text{回転} \mid \vec{x})} &= \frac{\frac{1}{2}\, p(\vec{x})}{\frac{1}{2}\, q(\vec{x})} \\ &= \frac{p(\vec{x})}{p(\mathbf{T}\vec{x})} \end{aligned} \tag{5}$$

であり, この対数が $\Lambda_{\mathbf{T}}(\vec{x})$ である. つまり $\Lambda_{\mathbf{T}}$ は, 正立と回転を見分ける最良 (ベイズ最適) の分類器が出す対数オッズそのものである.

平均の符号. $\Lambda_{\mathbf{T}}$ が平均としてどちらの符号をとるかは, 任意の密度 p'(分布内でも分布外でもよい) について成り立つ恒等式

$$\mathbb{E}_{\vec{x}\sim p'}[\Lambda_{\mathbf{T}}(\vec{x})] = \mathrm{KL}(p' \,\|\, q) - \mathrm{KL}(p' \,\|\, p) \tag{6}$$

で表せる. ここで $\mathrm{KL}(p' \,\|\, r) = \mathbb{E}_{\vec{x}\sim p'}[\log p'(\vec{x}) - \log r(\vec{x})]$ は, 分布 p' から見た分布 r との隔たり (カルバック・ライブラー情報量) で, 常に $\mathrm{KL} \geq 0$, 等号は $p' = r$ のときに限る. 証明：式 (4) により $p(\mathbf{T}\vec{x}) = q(\vec{x})$ と書き, 右辺に $\log p'(\vec{x})$ を足して引くと

$$\begin{aligned} \mathbb{E}_{\vec{x}\sim p'}[\Lambda_{\mathbf{T}}(\vec{x})] &= \mathbb{E}_{\vec{x}\sim p'}[\log p(\vec{x}) - \log q(\vec{x})] \\ &= \mathbb{E}_{\vec{x}\sim p'}\big[\{\log p'(\vec{x}) - \log q(\vec{x})\} - \{\log p'(\vec{x}) - \log p(\vec{x})\}\big] \\ &= \mathrm{KL}(p' \,\|\, q) - \mathrm{KL}(p' \,\|\, p) \end{aligned} \tag{7}$$

となる. 2 行目の第 1 の { } の期待値が $\mathrm{KL}(p' \,\|\, q)$, 第 2 の { } の期待値が $\mathrm{KL}(p' \,\|\, p)$ である (証明終). 分布内の画像 ($p' = p$) では第 2 項が $\mathrm{KL}(p \,\|\, p) = 0$ なので

$$\mathbb{E}_{\vec{x}\sim p}[\Lambda_{\mathbf{T}}(\vec{x})] = \mathrm{KL}(p \,\|\, q) \geq 0 \tag{8}$$

であり, 等号は回転しても分布が変わらない ($p = q$) ときに限る. つまり分布内のデータが向きをもつ限り $\Lambda_{\mathbf{T}}$ は平均として正になる (この $\mathrm{KL}(p \,\|\, q)$ が「向きの強さ」である). 一方, 分布外の p' では式 (6) の 2 つの項がどちらも正になりうるので, 右辺の符号は決まらない. 分布外のほうが分布内より強い向きをもつ (回転で分布が大きく変わる) ときは右辺が式 (8) を上回り, 分布内と分布外の平均の大小が入れ替わる (4 節では AUROC が 50%を下回った).

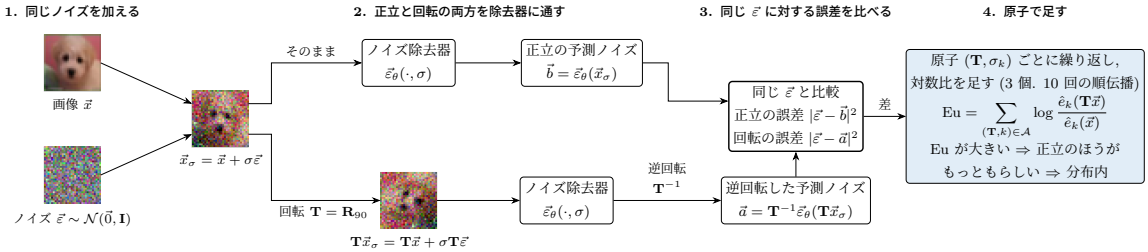


図 2 自己回転尤度比の共有ノイズ推定と Euphonium のスコア Eu の計算 (画像は CIFAR-10 の犬, $\mathbf{T} = \mathbf{R}_{90}$. 図のノイズ画像は見やすさのため $\sigma = 0.3$). 正立の画像に用いたノイズ画像 $\vec{x}_\sigma$ をそのまま回転して通し, 予測を逆回転して同じ $\vec{\varepsilon}$ と比べる. $\mathbf{T}\vec{x}_\sigma$ は回転した画像に回転したノイズ $\mathbf{T}\vec{\varepsilon}$ を加えたものに等しく, $\mathbf{T}\vec{\varepsilon}$ は $\vec{\varepsilon}$ と同じ分布に従うため, この手順は回転画像の誤差 $e_\sigma(\mathbf{T}\vec{x})$ の推定として正しい [式 (13)]. この犬の値：原子 $(\mathbf{R}_{90}, \sigma_7)$, すなわち $\sigma_7 = 0.25$ で $e(\vec{x}) = 0.054$, $e(\mathbf{T}\vec{x}) = 0.062$(画素あたり. 対数比 $+0.13$), 3 つの原子の対数比の和 $\mathrm{Eu} = +0.19$. $\mathbf{R}_{180}$ の原子も同じ手順で計算する.

3.2 共有ノイズによる推定

尤度比を予測誤差で書く. 拡散モデルは, ノイズ画像 $\vec{x} + \sigma\vec{\varepsilon}$($\vec{\varepsilon} \sim \mathcal{N}(\vec{0}, \mathbf{I})$ はガウスノイズ, $\sigma > 0$ はその大きさ) からノイズ $\vec{\varepsilon}$ を予測するノイズ除去器 $\vec{\varepsilon}_\theta(\cdot, \sigma)$ として用いる. 画像 $\vec{x}$ でのノイズ予測誤差 (ノイズについての期待値) を

$$e_\sigma(\vec{x}) = \mathbb{E}_{\vec{\varepsilon}}\big[\,|\vec{\varepsilon} - \vec{\varepsilon}_\theta(\vec{x} + \sigma\vec{\varepsilon}, \sigma)|^2\big] \tag{9}$$

とおく. 最適なノイズ除去器に対して, 対数尤度はこの誤差を σ について積分した形に書ける [15]：

$$\log p(\vec{x}) = -\tfrac{D}{2}\log(2\pi e) + \int_0^\infty \big[\tfrac{D}{1+\sigma^2} - e_\sigma(\vec{x})\big]\,\mathrm{d}\log\sigma \tag{10}$$

($\mathrm{d}\log\sigma = \mathrm{d}\sigma/\sigma$. 細かいスケールも粗いスケールも対数の目盛りで等しく数える). 式 (10) を $\vec{x}$ と $\mathbf{T}\vec{x}$ のそれぞれについて書き, 引き算する. 第 1 項と $D/(1+\sigma^2)$ の項は $\vec{x}$ によらないので消え,

$$\Lambda_{\mathbf{T}}(\vec{x}) = \int_0^\infty \big[e_\sigma(\mathbf{T}\vec{x}) - e_\sigma(\vec{x})\big]\,\mathrm{d}\log\sigma \tag{11}$$

を得る. 正立の画像のほうが回転した画像よりノイズを正確に予測できる ($e_\sigma(\vec{x}) < e_\sigma(\mathbf{T}\vec{x})$) スケールが多いほど, $\Lambda_{\mathbf{T}}$ は大きい.

同じノイズで測る. 式 (11) を使うには, 期待値 $e_\sigma(\vec{x})$ と $e_\sigma(\mathbf{T}\vec{x})$ を有限個 (本稿では各スケール 1 個) のノイズで近似する. 2 つの誤差を別々に引いたノイズで測ると, 各誤差に含まれる $|\vec{\varepsilon}|^2$ の揺らぎ (標準偏差 $\sqrt{2D}$. CIFAR の画像では約 78) が, 細かいスケールでの 2 つの誤差の差 (約 50) より大きく, 差が揺らぎに埋もれる. そこで 2 つの誤差を同じノイズ $\vec{\varepsilon}$ で測り, 差をとるときに $|\vec{\varepsilon}|^2$ が打ち消されるようにしたい. ただし比べるのは 2 つの異なる入力 $\vec{x}$ と $\mathbf{T}\vec{x}$ なので, 同じ $\vec{\varepsilon}$ を両方に加えてもノイズ画像は同じにならない. 鍵は, $\mathbf{T}$ が直交行列なので $\mathbf{T}\vec{\varepsilon}$ も $\vec{\varepsilon}$ と同じ分布 $\mathcal{N}(\vec{0}, \mathbf{I})$ に従うことである (平均は $\vec{0}$, 共分散は $\mathbf{T}\mathbf{I}\mathbf{T}^\top = \mathbf{I}$). したがって $e_\sigma(\mathbf{T}\vec{x})$ の定義でノイズを $\vec{\varepsilon}$ から $\mathbf{T}\vec{\varepsilon}$ に置き換えても期待値は変わらない. 正立の画像のノイズ画像を

$$\vec{x}_\sigma = \vec{x} + \sigma\vec{\varepsilon} \tag{12}$$

とおくと, $\mathbf{T}\vec{x} + \sigma\mathbf{T}\vec{\varepsilon} = \mathbf{T}\vec{x}_\sigma$ であるから

$$\begin{aligned} e_\sigma(\mathbf{T}\vec{x}) &= \mathbb{E}_{\vec{\varepsilon}}\big[\,|\mathbf{T}\vec{\varepsilon} - \vec{\varepsilon}_\theta(\mathbf{T}\vec{x}_\sigma, \sigma)|^2\big] \\ &= \mathbb{E}_{\vec{\varepsilon}}\big[\,|\vec{\varepsilon} - \mathbf{T}^{-1}\vec{\varepsilon}_\theta(\mathbf{T}\vec{x}_\sigma, \sigma)|^2\big] \end{aligned} \tag{13}$$

を得る. 2 行目では $|\mathbf{T}\vec{v}| = |\vec{v}|$ を $\vec{v} = \vec{\varepsilon} - \mathbf{T}^{-1}\vec{\varepsilon}_\theta(\mathbf{T}\vec{x}_\sigma, \sigma)$ に使った. つまり, 正立の画像に用いたノイズ画像 $\vec{x}_\sigma$ をそのまま回転してノイズ除去器に入力し, 出てきた予測を逆回転して, 正立の枝と同じ $\vec{\varepsilon}$ と比較すればよい (図 2). 回転の枝の予測を $\vec{a} = \mathbf{T}^{-1}\vec{\varepsilon}_\theta(\mathbf{T}\vec{x}_\sigma, \sigma)$, 正立の枝の予測を $\vec{b} = \vec{\varepsilon}_\theta(\vec{x}_\sigma, \sigma)$ とおくと, 1 つのノイズでの 2 つの誤差の差は

表 2 比較手法との比較 (AUROC, %). 左：CIFAR-10 を分布内とする 9 つの自然画像の分布外集合と平均. 右：ほかの 5 つの分布内での自然画像の分布外集合 (順に 9, 9, 9, 7, 4 集合) の平均. †：8 つの比較手法の最良. **水色の太字**：Ours が比較手法の最良に並ぶか上回る列 (0.05 ポイント以内は同点). 下線：最良にだけ下回る列 (2 位). Ours：式 (16) の Euphonium. Ablation：PF-ODE による厳密な Λ_{90}(印はつけない).

	分布内：CIFAR-10(分布外の集合ごと)										分布内を変えた場合 (平均)				
手法	SVHN	Textures	CelebA	Tiny-IN	LSUN	ImageNet	ImageNet32	Places365	CIFAR-100	平均	SVHN	CelebA	CIFAR-100	ImageNet-64	FashionMNIST
NLL(尤度)	12.5	62.3	61.3	49.1	72.1	58.6	76.9	69.7	50.2	57.0	98.9	81.6	56.4	54.7	33.1
IC (PNG)	81.7	74.7	65.8	48.6	83.7†	76.7	83.0	82.6†	55.7	72.5	92.7	86.7	67.1†	49.8	87.3
IC (J2K)	96.0	74.1	67.7†	45.9	77.8	72.0	74.2	77.4	54.4	71.1	75.5	81.5	66.3	47.0	40.0
TT	73.6	66.2	39.9	47.4	61.6	59.0	73.7	63.1	54.7	59.9	98.6	84.9	54.2	57.4	62.1
MSMA 型	91.1	90.1†	43.7	71.5	48.4	59.0	70.4	52.4	54.5	64.6	99.0	99.6	59.1	62.4†	95.8†
DiffPath	99.4†	85.3	39.4	77.4†	62.4	73.6	84.3†	65.3	60.3	71.9	99.5†	99.8†	63.2	55.3	81.3
GEPC	84.7	66.0	28.9	50.9	35.0	47.2	47.2	41.1	49.7	50.1	91.8	98.7	55.5	49.1	84.0
EigenScore	66.8	72.1	61.4	76.9	83.6	79.3†	78.2	80.9	76.1†	75.0†	86.1	86.1	44.9	44.1	93.5
Ours：Euphonium(10 回)	94.9	**94.8**	**91.7**	**93.8**	**92.2**	**93.5**	**92.4**	**91.6**	**76.0**	**91.2**	98.0	**100.0**	**72.8**	60.5	**98.9**
Ablation：厳密な比 Λ_{90}(512 回)	95.9	94.6	94.8	93.5	90.3	91.8	89.9	89.7	71.1	90.2	89.6	–	73.0	62.6	–

$$
\begin{aligned}
|\vec{\varepsilon}-\vec{a}|^2-|\vec{\varepsilon}-\vec{b}|^2 &= |\vec{a}|^2-|\vec{b}|^2-2\vec{\varepsilon}\cdot(\vec{a}-\vec{b}) \\
&= (\vec{a}-\vec{b})\cdot(\vec{a}+\vec{b}-2\vec{\varepsilon}) \qquad (14)
\end{aligned}
$$

となる ($|\vec{\varepsilon}-\vec{a}|^2=|\vec{\varepsilon}|^2-2\vec{\varepsilon}\cdot\vec{a}+|\vec{a}|^2$ と展開して引いた). $|\vec{\varepsilon}|^2$ の項は消え, 揺らぐのは $\vec{a}-\vec{b}$(回転に対する予測のずれ) に比例する分だけである.

3.3 Euphonium：10 回の順伝播の向きの統計量

積分を和にする. ノイズの大きさを, $\log\sigma$ について等間隔な格子 $\sigma_k = 0.01\times 3162.3^{(k-1)/15}(k=1,2,\ldots$. 隣との間隔は $h=0.537$) にとり, 式 (11) の積分を幅 h の長方形の和で近似する. 用いるのは細かい側の 10 点, $\sigma_1=0.01$ から $\sigma_{10}=1.26$ まで (この窓の決め方は後述). スケール σ_k での e_{σ_k} の推定値 [式 (13) を 1 つのノイズで近似したもの] を $\hat{e}_k$ と書くと

$$
\begin{aligned}
\Lambda_{\mathbf{T}}(\vec{x}) &\approx h\sum_{k=1}^{10}\left[\hat{e}_k(\mathbf{T}\vec{x})-\hat{e}_k(\vec{x})\right] \\
&\approx h\sum_{k=1}^{10}\hat{e}_k(\vec{x})\log\frac{\hat{e}_k(\mathbf{T}\vec{x})}{\hat{e}_k(\vec{x})} \qquad (15)
\end{aligned}
$$

となる. 2 つ目の近似は, 差を $\hat{e}_k(\mathbf{T}\vec{x})-\hat{e}_k(\vec{x})=\hat{e}_k(\vec{x})\,u_k$($u_k$ は相対的な差) と書き, $|u|$ が小さいときの $u\approx\log(1+u)$ を使って $u_k\approx\log\{\hat{e}_k(\mathbf{T}\vec{x})/\hat{e}_k(\vec{x})\}$ としたものである. ノイズは, スケールごとに 1 つの $\vec{\varepsilon}$ を引いて $+\vec{\varepsilon}$ と $-\vec{\varepsilon}$ の両方で評価して平均し (符号反転対), すべてのテスト画像に同じノイズを用いる.

重みを外す. 式 (15) の右辺は, スケール k の対数比 $\log\{\hat{e}_k(\mathbf{T}\vec{x})/\hat{e}_k(\vec{x})\}$ に重み $\hat{e}_k(\vec{x})$ をかけて足したものである. この重みとその揺らぎは細かいスケールほど大きい (σ_1 では平均 $0.52D$, σ_{10} では $0.02D$) ので, 細かいスケールの項が和を支配する. そこで検知には, 重みを外して対数比だけを足した向きの統計量を用いる. 回転 $\mathbf{T}$ とスケール k の組を原子と呼び, 用いる原子の集合を $\mathcal{A}$ として

$$
\mathrm{Eu}(\vec{x}) = \sum_{(\mathbf{T},k)\in\mathcal{A}}\log\frac{\hat{e}_k(\mathbf{T}\vec{x})}{\hat{e}_k(\vec{x})} \qquad (16)
$$

$$
\mathcal{A} = \{(\mathbf{R}_{90},1),\,(\mathbf{R}_{90},7),\,(\mathbf{R}_{180},1)\} \qquad (17)
$$

とする ($\mathbf{R}_{90}$ は σ_1, σ_7；$\mathbf{R}_{180}$ は σ_1). 正立の画像は $\mathcal{A}$ に現れる 2 つのスケールで $\pm\vec{\varepsilon}$ の計 4 回, 回転画像は 3 つの原子ごとに $\pm\vec{\varepsilon}$ の計 6 回, 合わせて 1 枚 10 回の順伝播である. これが提案手法 Euphonium のスコアである (本文と表では Euphonium, 式では Eu と書く). Euphonium は $\Lambda_{\mathbf{T}}$ の推定値ではない. 各原子の証拠を画像ごとの誤差 $\hat{e}_k(\vec{x})$ で割って正規化し, 等しい重みで足した別の統計量であり, 式 (11) の積分の格子のうち証拠のあるスケールだけを 2 つの回転について用いる (4 節で両者を分けて検証する).

各スケールの符号. 式 (6) は積分全体についての主張だが, 各スケールの項 $e_\sigma(\mathbf{T}\vec{x})-e_\sigma(\vec{x})$ も, 分布内の画像で平均すればすべての σ で非負である. 理由は次のとおり. $\mathbb{E}_{\vec{x}\sim p}[e_\sigma(\vec{x})]$ は, 分布 p の画像にノイズを加えたものから $\vec{\varepsilon}$ を当てるときの, 最良の推定器 (p に最適な $\vec{\varepsilon}_\theta$) の誤差, すなわち最小誤差である.

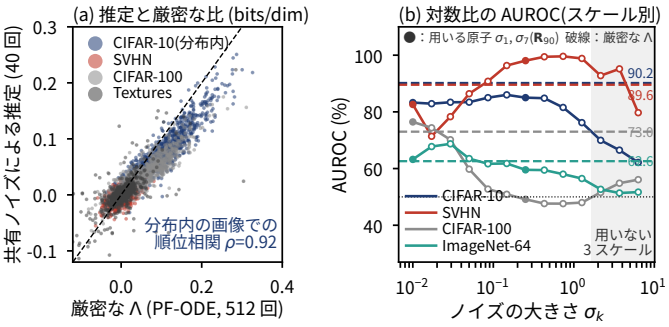


図 3 推定量と Euphonium をそれぞれ厳密な比と照合する ($\mathbf{T} = \mathbf{R}_{90}$). (a) 10 スケールの共有ノイズ推定 [式 (15) の第 1 の近似, 40 回] と PF-ODE による厳密な Λ(512 回. CIFAR-10 のモデル). 推定は $\sigma \leq 1.26$ の和なので値は小さいが順位は保たれる. (b) スケールごとの対数比 $\log \hat{e}_k(\mathbf{R}_{90}\vec{x})/\hat{e}_k(\vec{x})$ の AUROC(自然画像の分布外集合の平均. 13 スケール, 4 つの分布内). 塗りつぶした点が Euphonium の用いる原子 [$\mathbf{R}_{90}$ は σ_1, σ_7；$\mathbf{R}_{180}$ は σ_1. $\mathbf{R}_{180}$ の対数比は補足資料の図 A1(b) に示す](σ_{11}–σ_{13} は Euphonium にも推定量にも用いない), 破線は厳密な Λ の AUROC.

一方 $\mathbb{E}_{\vec{x}\sim p}[e_\sigma(\mathbf{T}\vec{x})]$ は, 回転した画像 (分布 q) に同じ $\vec{\varepsilon}_\theta$ を使ったときの誤差であり, q に合わせた最良の推定器の誤差 (q の最小誤差) 以上である. $\mathbf{T}$ が直交でノイズが等方的なので, 問題全体を $\mathbf{T}$ で回しても何も変わらず, q の最小誤差は p の最小誤差に等しい. よって $\mathbb{E}_{\vec{x}\sim p}[e_\sigma(\mathbf{T}\vec{x})] \geq \mathbb{E}_{\vec{x}\sim p}[e_\sigma(\vec{x})]$ である. したがってスケールの一部だけを足しても, 分布内での平均の符号は保たれる [対数比では近似的. 補足資料の図 A1(b) で確かめる].

構成の決め方. 原子の集合 $\mathcal{A}$ は, 主評価に含まれない分布外データセット (STL-10, GTSRB, EuroSAT など 11 集合) と分布内の開発用画像での AUROC の 6 つの分布内での平均を基準に選び, 主評価のデータは用いていない. 候補は, 回転 $\mathbf{R}_{90}$, $\mathbf{R}_{180}$, $\mathbf{R}_{270}$ とスケール σ_1–σ_{10} の原子を 1 枚 10 回以内で組み合わせた 1285 通りすべてで, 式 (17) はその最良 (85.7%) である (0.1 ポイント以内は同点とし, 同点の中では順伝播が少なく, 最も弱い分布内の平均が高いものを採る. 補足資料の A.4). 対数比の形 [式 (15) の第 2 の近似] は, 細かいスケールの重みを外すという上の理由による設計上の選択であり, 選択用データで選んだものではない. 誤差の差の形 [同じ式の第 1 の近似] で同じ探索をすると, 選択用データでは 86.9%と対数比の形を上回り, 主評価では 85.4%と下回る (補足資料の A.4). σ_{11}–σ_{13} の原子は, 候補に加えても選択用データの上位に入らない (A.4). 逆伝播は用いない.

4. 実験と結果

設定. 分布内データは 6 つで, FashionMNIST 以外は公開の学習済み拡散モデルをそのまま使った (補足資料の表 A1). 主な実験は CIFAR-10 の EDM [2](VP, DDPM++) で行う. 比較手法は尤度 (NLL) と 2 節の手法の計 8 つ (IC は PNG と JPEG2000 を別に数える) で, 公式のコードまたは論文の手順に従い, 同じモデルと同じ画像で評価した. 当てはめには開発用, 評価には最終評価用の画像を使い, PF-ODE を用いる手法は 1 集合あたり 1000 枚 (ImageNet-64 は 500 枚) で評価した.

推定の検証：推定量と Euphonium を分けて照合する. 式 (11) の被積分関数は, 分布内の CIFAR-10 ではすべてのスケールで正, SVHN と Textures では 0 に近い [補足資料の図 A1(a)]. 10 スケールの共有ノイズ推定 (40 回) と厳密な比の順位相関は, 厳密な比を計算した 4 つの分布内データセットの分布内画像で 0.61(SVHN)–0.92[CIFAR-10. 図 3(a)] であり, 推定は厳密な比の順位をおおむね再現する (ノイズを独立に引くと, CIFAR-10 を分布内とする 12 組の平均 AUROC が 92.2%から 86.5%に下がる. 補足資料の表 A4). 一方, 検知に用いる Euphonium 自体と厳密な比の順位相関は分布内画像で 0.35–0.78, 分布内と分布外を合わせても 0.62–0.76 にとどまる (補足資料の図 A2). 理由は図 3(b) にある. 対数比の証拠は分布内ごとに別のスケールにあり, SVHN(数字) では粗いスケール (σ_9 で 99.6%, σ_1 では 82.6%), CIFAR-100 では細かいスケール (σ_1 で 76.5%, σ_5, σ_7, σ_9 では約 50%) にある. 差の形 [図 3(a) の推定量] は厳密な比の順位を保ち, 平均 AUROC も厳密な比の側に寄る (CIFAR-100 で 72.1%, SVHN で 78.2%). 対数比はこれを画像ごとの誤差 $\hat{e}_k(\vec{x})$ で正規化するので, 誤差の小さい単純な画像では差が増幅され, スケール間の重みも等しくなる. そのため SVHN を分布内とする平均は Euphonium の 98.0%に対し厳密な比では 89.6%である. CIFAR-100 では, 証拠のない粗いスケールまで等しく足した $\mathbf{R}_{90}$ の 10 スケールの対数比の和は

表 3 符号か大きさか：自然画像の分布外集合での平均 AUROC(%). Euphonium と $-|\mathrm{Eu}|$ は同じ 10 回の評価から. 最終列は GEPC の実行 (GEPC の 6 つのノイズレベルすべて. 本研究のスケールとは異なる) の $\mathbf{R}_{90}$ の予測差 $\|\vec{a}-\vec{b}\|^2/\|\vec{b}\|^2$ を「大きいほど分布外」と読んだもの. 全列は補足資料の表 A6.

分布内	Ours：Euphonium	$-\lvert\mathrm{Eu}\rvert$	$\mathbf{R}_{90}$ の予測差 (GEPC の実行)
CIFAR-10	91.2	9.9	28.8
SVHN	98.0	5.4	96.0
CelebA	100.0	0.0	1.3
CIFAR-100	72.8	29.3	47.1
ImageNet-64	60.5	39.0	52.7
FashionMNIST	98.9	4.0	13.7
平均	86.9	14.6	39.9

60.2%と厳密な比 (73.0%) を大きく下回るが, Euphonium は証拠のある σ_1 に原子を置くため 72.8%と厳密な比に並ぶ (補足資料の表 A9). 粗い 3 スケール ($\sigma = 2.15$–6.31) の対数比の AUROC は CIFAR-10 で 70.0–62.2%と低く, 10 スケールの和に加えると平均が 91.0%から 87.2%に下がる (補足資料の表 A9). 開発用の分割で決めた $\sigma \le 1.26$ の窓はこれと整合する (事後の確認. $\sigma \gg 1$ では向きの情報が残らない).

比較手法との比較. 表 2 に 9 つの分布外集合での AUROC を示す. 尤度 (NLL) の平均は 57.0%で, SVHN では 12.5%である. Euphonium は平均 91.2%で, 9 つの集合すべてで尤度を上回る. 比較手法の最良は EigenScore の 75.0%であり, Euphonium は 9 つのうち 8 つの集合で比較手法の最良に並ぶか上回り, 残る SVHN では DiffPath の 99.4%, IC (J2K) の 96.0%に対し 94.9%(3 位) である. 厳密な比 Λ_{90}(512 回) の平均は 90.2%で 10 回の Euphonium と同等だが, 集合ごとには異なる. なお, 同じモデルのノイズ除去器の特徴による分布内の学習画像への kNN [16](特徴の最近傍. 本稿の比較手法には含めず, 最終発表で扱う) は CIFAR-10 で 92.5%, 6 つの分布内の平均で 90.1%であり, Euphonium 単独は 5 つの分布内でこれに及ばない. 本稿の「比較手法の最良」は公表された 8 つの手法の中での最良を指す.

符号か大きさか. 表 3 に, 同じ 10 回の評価から符号を捨てた統計量を示す. $-|\mathrm{Eu}|$ の平均 AUROC は CIFAR-10 で 9.9%, 6 つの分布内の平均で 14.6%と 50%を大きく下回る. 回転に対する予測の不整合は分布内の正立画像でこそ大きく, SVHN や Textures のような分布外の画像では回転しても誤差が変わらないからである [補足資料の図 A1(a)]. したがって読み方を反転した $|\mathrm{Eu}|$ は Euphonium に近く (6 つの平均で 85.4%), 画像ごとの符号の寄与は小さく, 効いているのは不整合の向き (分布内で大きい) である. 符号が効くのは分布外のほうが強い向きをもつ組で, そこでは Euphonium も $|\mathrm{Eu}|$ も反転し (CIFAR-100 に対する CIFAR-10 で Euphonium は 24.4%),「大きいほど分布外」の読み方が当たる (75.4%). GEPC の実行の $\mathbf{R}_{90}$ の予測差のノルムは, 分布内によって向きが変わる (表 3 の最終列). 本研究と GEPC の違いは符号そのものより, 同じ $\vec{\varepsilon}$ に対する誤差の差 (尤度比の被積分関数) を測るかノルムを測るかにあると考えられるが, 同じ 10 回の評価からの $\|\vec{a}_k-\vec{b}_k\|^2$ との対照は計算中である.

分布内データセットを変えた場合. 表 2 の右に, ほかの 5 つの分布内データセットでの平均を示す. Euphonium は 6 つのうち 4 つで比較手法の最良に並ぶか上回り, 全 63 組 (補足資料の表 A10, A11) では 34 組で並ぶか上回り, 8 組で 2 位であった. 下回るのは SVHN, ImageNet-64 である. SVHN では尤度だけで 98%に達し, 比較手法の最良 (DiffPath) の 99.5%に対し Euphonium は 98.0%である [$\mathbf{R}_{180}$ の原子は数字では弱い (補足資料の A.4). $\mathbf{R}_{90}$ だけの構成 (A.4 の c3) なら 99.6%]. 向きの弱い CIFAR-100 と ImageNet-64($\overline{\mathrm{Eu}}$ が 0.08 と 0.04. 補足資料の表 A8) では Euphonium は 72.8%, 60.5%で, 前者は比較手法の最良 (67.1%) を上回り, 後者は下回る (62.4%). 平均を下げているのは CIFAR-100 に対する CIFAR-10(24.4%), ImageNet-64 に対する CelebA(6.6%) のように分布外のほうが強い向きをもつ組であり, 式 (6) の片側性のとおり反転は厳密な比でも起こる (29.4%, 25.2%). 向きの弱さがデータの性質か学習不足かを分けるため, CIFAR-10 と CIFAR-100 の両方のモデルで両方の画像を評価した (補足資料の表 A7). どちらのモデルでも CIFAR-10 の画像の $\overline{\mathrm{Eu}}$ は 0.16 と 0.17, CIFAR-100 の画像は 0.07 と 0.08 であり (厳密な比でも同じ), 差はモデルではなく画像の側にあり, 反転の主因は学習量ではなくデータの性質と考えられる (補足資料の A.7. ImageNet-64 に対する CelebA も $\overline{\mathrm{Eu}}$ が 0.11 対 0.04 と分布外のほうが大きい).

5. 今後の課題

回転との比は片側の判定であり, 分布外のほうが強い向きをもつ組で反転する. 今後は, 学習した回転分類器との直接の比較に加え, 反転する条件を分布内の画像だけから見積もる方法, 分布内ごとに異なる証拠のスケール [図 3(b)] の重みを開発用画像だけから決める方法, 同じ 10 回の評価から得る向きによらない統計量で反転を補う規則を検討する.

参考文献

[1] Song, Y., Sohl-Dickstein, J., Kingma, D. P., Kumar, A., Ermon, S. and Poole, B.: Score-Based Generative Modeling through Stochastic Differential Equations, *Proc. ICLR* (2021).

[2] Karras, T., Aittala, M., Aila, T. and Laine, S.: Elucidating the Design Space of Diffusion-Based Generative Models, *Proc. NeurIPS* (2022).

[3] Nalisnick, E., Matsukawa, A., Teh, Y. W., Gorur, D. and Lakshminarayanan, B.: Do Deep Generative Models Know What They Don't Know?, *Proc. ICLR* (2019).

[4] Serrà, J., Álvarez, D., Gómez, V., Slizovskaia, O., Núñez, J. F. and Luque, J.: Input Complexity and Out-of-distribution Detection with Likelihood-based Generative Models, *Proc. ICLR* (2020).

[5] Golan, I. and El-Yaniv, R.: Deep Anomaly Detection Using Geometric Transformations, *Proc. NeurIPS* (2018).

[6] Hendrycks, D., Mazeika, M., Kadavath, S. and Song, D.: Using Self-Supervised Learning Can Improve Model Robustness and Uncertainty, *Proc. NeurIPS* (2019).

[7] Tack, J., Mo, S., Jeong, J. and Shin, J.: CSI: Novelty Detection via Contrastive Learning on Distributionally Shifted Instances, *Proc. NeurIPS* (2020).

[8] Nalisnick, E., Matsukawa, A., Teh, Y. W. and Lakshminarayanan, B.: Detecting Out-of-Distribution Inputs to Deep Generative Models Using Typicality, *arXiv:1906.02994* (2019).

[9] Mahmood, A., Oliva, J. and Styner, M.: Multiscale Score Matching for Out-of-Distribution Detection, *Proc. ICLR* (2021).

[10] Heng, A., Thiery, A. H. and Soh, H.: Out-of-Distribution Detection with a Single Unconditional Diffusion Model, *Proc. NeurIPS* (2024).

[11] Shoushtari, S., Wang, Y., Shi, X., Asif, M. S. and Kamilov, U. S.: EigenScore: OOD Detection using Posterior Covariance in Diffusion Models, *Proc. ICLR* (2026).

[12] Alexis, R. Y., Pinsolle, J., Terreaux, E., Morisseau, C., Ovarlez, J.-P. and Ren, C.: GEPC: Group-Equivariant Posterior Consistency for Out-of-Distribution Detection in Diffusion Models, *Proc. ICML* (2026).

[13] Li, A. C., Prabhudesai, M., Duggal, S., Brown, E. and Pathak, D.: Your Diffusion Model is Secretly a Zero-Shot Classifier, *Proc. ICCV* (2023).

[14] Chen, H., Dong, Y., Wang, Z., Yang, X., Duan, C., Su, H. and Zhu, J.: Robust Classification via a Single Diffusion Model, *Proc. ICML* (2024).

[15] Kong, X., Brekelmans, R. and Steeg, G. V.: Information-Theoretic Diffusion, *Proc. ICLR* (2023).

[16] Sun, Y., Ming, Y., Zhu, X. and Li, Y.: Out-of-Distribution Detection with Deep Nearest Neighbors, *Proc. ICML* (2022).

[17] Kamkari, H., Ross, B. L., Cresswell, J. C., Caterini, A. L., Krishnan, R. G. and Loaiza-Ganem, G.: A Geometric Explanation of the Likelihood OOD Detection Paradox, *Proc. ICML* (2024).

[18] Nichol, A. Q. and Dhariwal, P.: Improved Denoising Diffusion Probabilistic Models, *Proc. ICML* (2021).

[19] Karras, T., Aittala, M., Lehtinen, J., Hellsten, J., Aila, T. and Laine, S.: Analyzing and Improving the Training Dynamics of Diffusion Models, *Proc. CVPR* (2024).

[20] Zhang, J., Yang, J., Wang, P., Wang, H., Lin, Y., Zhang, H., Sun, Y., Du, X., Li, Y., Liu, Z., Chen, Y. and Li, H.: OpenOOD v1.5: Enhanced Benchmark for Out-of-Distribution Detection, *arXiv:2306.09301* (2023).

補足資料

A.1 実験の設定

表 A1 分布内データセットと拡散モデル. 5 つは公開されている学習済みの重みを変更せずに用いた.

分布内	解像度	モデル	出典
CIFAR-10	32×32	EDM(VP, DDPM++)	[2]
CIFAR-100	32×32	EDM の前処理による DDPM++	[14]
SVHN	32×32	VP-SDE	[17]
CelebA	32×32	iDDPM	[18]
ImageNet-64	64×64	EDM2-XS(条件なし)	[19]
FashionMNIST	32×32	EDM の前処理による U-Net	本研究で学習

分布外集合は, 32×32 の分布内データセットに対しては他の自然画像のデータセット [CIFAR-10/100, SVHN, CelebA, Textures(DTD), Tiny-ImageNet(検証画像を 32×32 に縮小), LSUN と ImageNet(CSI [7] が配布するリサイズ版), ImageNet32(ダウンサンプル版の検証画像), Places365(検証画像)], ImageNet-64 に対しては OpenOOD v1.5 [20] の集合 (SSB-hard, NINCO, iNaturalist, Textures, OpenImage-O) と Places365, CelebA, FashionMNIST に対しては 32×32 に埋め込んだ灰色画像の集合 (MNIST, KMNIST, Omniglot, notMNIST) である. さらに各分布内データセットについてその画像を上下反転した集合を加え, ImageNet-64 以外には一様ノイズと定数画像も加えた (計 63 組). 上下反転した分布内の画像は, 内容は分布内と同じで向きだけが異なる集合であり, 向きの手がかりを直接評価する. Euphonium は分布内の開発用画像には依存しないが, ノイズの乱数はすべての画像で共通にした. Euphonium の構成 (回転, スケール, ノイズの引き方) は主評価に含まれないデータだけで選んだ (A.4). 比較手法の当てはめには分布内の開発用画像を用いた. MSMA 型は, 20 スケールでのスコアの大きさのベクトルの, 分布内の開発用画像に対するマハラノビス距離である. DiffPath, GEPC, EigenScore は公式のコードに従って再実装した：DiffPath は DDIM 10 段の軌跡の 6 次元の統計量にガウス混合を当てはめる. GEPC は 6 変換 (左右・上下反転, $\mathbf{R}_{90}$, $\mathbf{R}_{180}$, 縦・横 1 画素の巡回シフト) の予測差を公開設定のノイズレベルで測り (CIFAR-10, SVHN, CelebA は各自の公開設定, CIFAR-100, ImageNet-64, FashionMNIST には CIFAR-10 の設定. レベルの選択と密度推定は分布内の開発用画像で行う), EigenScore は 5 つの時刻での事後共分散の上位 3 固有値を分布内で z 化して足す. PF-ODE を用いる手法 (NLL, IC, TT, Λ_{90}. 厳密な尤度は Heun 法 64 段で順伝播と逆伝播を 128 回ずつ, 比はその 2 倍の計 512 回) は 1 集合あたり 1000 枚 (ImageNet-64 は 500 枚) で評価し, 合成画像の集合では計算していない. 厳密な Λ_{90} は CIFAR-10, SVHN, CIFAR-100, ImageNet-64 の 4 つの分布内で計算し (CelebA と FashionMNIST では計算していない), 上下反転の集合でも計算していない. DiffPath と GEPC の再実装は, 論文の設定 (32×32 の全分布内に 1 つの CelebA モデル) では論文に載る 6 組の公表値をほぼ再現する (公表値との差は DiffPath で最大 3.1 ポイント, GEPC は公式コードの時刻の扱いで最大 3.9 ポイント). EigenScore は公式コードがなく, 論文の 9 組の平均 92.5%に対し再実装は 79.5%で, モデルの違い (本稿は各分布内の公開モデル, 論文は 1 つの CelebA モデル) と論文が指定しない設定によると考えられる. 本文の表の値はすべての手法が共通にもつ画像 (各集合 1000 枚, ImageNet-64 は 500 枚, 合成画像は 2000 枚) で計算した. 「自然画像の分布外集合」は上下反転と合成画像を除いた分布外集合を指す (FashionMNIST の灰色画像の集合を含む).

A.2 計算量と処理時間

Euphonium は 1 枚あたり 10 回の順伝播 (0.42 TFLOP) で計算でき, 逆伝播を用いないため推論専用の環境でも動作する (表 A2). PF-ODE による尤度 (NLL, TT, IC) は順伝播と逆伝播を 128 回ずつ要し, 厳密な自己回転尤度比はその 2 倍である.

A.3 向きの統計量 Euphonium の中身

図 A1(a) は式 (11) の被積分関数,(b) は式 (16) の対数比を $\mathbf{R}_{90}$ と $\mathbf{R}_{180}$ についてスケールごとに示

表 A2 1 枚あたりの計算量と処理時間 (CIFAR-10 のモデル, EDM DDPM++, 5600 万パラメータ). NFE：順伝播の回数, VJP：逆伝播 (ベクトルとヤコビ行列の積) の回数. TFLOP は 1 回の順伝播 42.4 GFLOP, 順伝播と逆伝播の組 85.1 GFLOP の実測から. CPU 時間はすべての行を同じ 2 コアの CPU で 1 回のセッションの中で測定した (fp32, 4 枚ずつのバッチ, 同じ構造のネットワークで重みは乱数. 計算量は重みによらない. 時間はほぼすべてネットワークの評価で, Euphonium の集計は無視できる). IC の時間は尤度の計算に PNG / JPEG 2000 の符号長の計算 (1 枚 0.002 秒) が加わる. GPU(GeForce RTX 2080 Ti, fp16, 500 枚ずつ) では 20 回の構成 (c3) の評価が 1 枚 38.3 ミリ秒だった (Euphonium の GPU 時間は未計測. 順伝播の回数は c3 の半分). 水色の行が Ours.

手法	NFE	VJP	TFLOP	CPU 秒/枚
DiffPath	10	0	0.42	2.2
Ours：Euphonium(10 回の順伝播)	10	0	0.42	2.1
GEPC	14	0	0.59	3.1
Ablation：格子の候補 c3($\mathbf{R}_{90}$, 5 スケール. A.4)	20	0	0.85	4.3
MSMA 型	20	0	0.85	4.3
Ablation：$\mathbf{R}_{90}+\mathbf{R}_{180}$, 10 スケール (A.4 の r60)	60	0	2.54	13.1
EigenScore	180	0	7.63	40.3
NLL, TT, IC (PNG / J2K)	128	128	10.89	59.9
Ablation：厳密な比 Λ_{90}(PF-ODE)	256	256	21.79	115.2

し, Euphonium の用いる 3 つの原子 [式 (17)] を印で示したものである. 図 A1(c) は 3 つの対数比の和 Euphonium の分布で, 分布内の画像の 98.1%で Eu >0 である一方, SVHN の中央値は -0.003 である.

A.4 規則の選択と Ablation：主評価に含まれないデータだけで選ぶ

表 A3 に候補と結果を示す. 候補の比較に主評価の分布外データセット (とその開発用の複製) は用いていない (選択用の Imagenette は ImageNet の 10 クラスの部分集合で, 主評価の ImageNet32・ImageNet と出典が重なるが画像は別である).

原子の集合の選択. 候補は対の原子の集合に限った ($+\bar{\varepsilon}$ だけの候補や対との混合は, 別の乱数の実行の値を足し合わせることになるため除いた). 上位の 3 つ (e10, e10b, e10c) は 85.75, 85.70, 85.65%で 0.1 ポイント以内の同点であり, 順伝播もすべて 10 回なので, 最も弱い分布内の平均 (54.4, 53.6, 52.6%) が最も高い e10 を採用した. この同点の規則は, 上位 2 つの順位が計算に用いる開発用画像の集合 (全画像か, $+\bar{\varepsilon}$ だけの実行とも共通の画像か) によって入れ替わることがわかった時点で定めたものである. どの候補を採っても主評価の結論は変わらない (e10b は主評価 87.5%で 36 組, e10c は 87.5%で 37 組). 選択用の分布外集合を交互に 2 分割し, 片方で候補を選んでもう片方で確かめても, どちらの分割でも選ばれた構成は格子の候補の最良 (c3) を上回った (88.0 対 87.7, 83.0 対 80.6). この探索は, 格子の候補 (下段) の主評価を見たあとに行ったが, 選択には主評価のデータを一切用いていない.

対数比の形とスケールの範囲. 対数比の形 [式 (15) の第 2 の近似] は 3.3 節の理由による設計上の選択であり, 選択用データで選んだものではない. 同じ候補の族を誤差の差の形 (第 1 の近似) で評価すると, 選択用データでの最良は $\mathbf{R}_{90}$：σ_9；$\mathbf{R}_{180}$：σ_1；$\mathbf{R}_{270}$：σ_9(86.9%. 最も弱い分布内は 64.6%) で, 対数比の形の 85.7%を上回る. 主評価では 85.4%(36 組) で, Euphonium の 86.9%(34 組) を平均で下回り, SVHN を分布内とする平均が 86.3%に下がる (対数比は誤差の小さい単純な画像で差を増幅する. 4 節). Euphonium と同じ 3 つの原子を差の形で足した「差 Eu」(表 A9) は主評価 84.3%(36 組. 6 つの分布内のうち 5 つで比較手法の最良に並ぶか上回る) で, 下がるのは SVHN(73.5%) だけである. スケールの範囲は, 候補を $\sigma_{13}=6.31$ までの原子に広げても (FashionMNIST の開発用の実行は 10 スケールまでのため, ほかの 5 つの分布内で) 上位 10 候補に σ_{11}–σ_{13} の原子は入らない (対数比・差のどちらの形でも). 当初, 対数比の形と $\sigma\le 1.26$ の窓は, 最終評価用の画像を開く前に主評価と同じ分布外データセットの開発用の複製で決めていた. これは主評価に含まれないデータだけで選ぶという本稿の規則に反するため, 上のとおり選択用データで確かめ直した：窓の結論は同じで, 対数比の形は選択用データでは支持されない.

Ablation：格子の候補と順伝播の回数. 向きに共通のスケールの格子を用いる 20 回以内の 12 候補 (c1–c12. 分布内の分布が左右対称なら $\mathbf{R}_{270}$ は $\mathbf{R}_{90}$ と, $\mathbf{R}_{180}$ は上下反転と同じ証拠をもつため, 回転は $\mathbf{R}_{90}$ と $\mathbf{R}_{180}$ とその組とし, 参考として $\mathbf{R}_{270}$ を加えた候補も載せる) の選択用データでの最良は c3($\mathbf{R}_{90}$, 奇の 5 点, 対) の 83.9%で, 2–4 位 (c9, c5, c11) との差は 0.3 ポイント程度である. 主評価では 12 候補は

表 A3 Euphonium の構成の選択 (上) と格子の候補の Ablation(下). 選ばれた構成が Ours(水色の行). 上：原子 (回転, スケール) の集合. 回転は $\mathbf{R}_{90}$, $\mathbf{R}_{180}$, $\mathbf{R}_{270}$, スケールは σ_1–σ_{10}, ノイズは符号反転対 (対) で, 10 回以内の 1285 通りのうち選択用データで上位の 3 つ (e10, e10b, e10c) と, 予算を 8, 6, 4 回に絞ったときの最良 (e8, e6, e4. 参考). 下：向きに共通のスケールの格子を用いる候補. 格子 $\sigma_1, \ldots, \sigma_{10}$ を 1 つおきに間引いたもの (奇：$\{\sigma_1, \sigma_3, \sigma_5, \sigma_7, \sigma_9\}$, 偶：$\{\sigma_2, \ldots, \sigma_{10}\}$),3 つおき, または全 10 点で, ノイズは対か $+\vec{\varepsilon}$ だけ (単). c1–c12 は 20 回以内, r60, r80 は 10 スケールすべてを用いる 60 回と 80 回の構成, dev は主評価と同じ分布外データセットの開発用の複製で候補を選ぶとどうなるかを示す参考値 (採用しない). 「選択」：分布内の開発用画像と主評価に含まれない分布外データセット [32×32 の 4 モデルでは STL-10, GTSRB, Flowers-102, EuroSAT, MNIST, Oxford-IIIT Pet, Caltech-101, Food-101, FGVC-Aircraft, Imagenette, Rendered SST-2. ImageNet-64 は同じ集合の 64×64 版 (Imagenette を除く 10 集合), FashionMNIST は灰色の文字・数字・自然画像の 6 集合] での AUROC の 6 つの分布内での平均 (この列で選ぶ). 「主評価」：採用後に計算した自然画像の分布外集合での AUROC の 6 つの分布内での平均と, 全 63 組のうち比較手法の最良に並ぶか上回った組の数 (選択には用いていない).

	向き	スケール	ノイズ	NFE	選択	主評価	勝ち数
Ours(e10)	$\mathbf{R}_{90}$, $\mathbf{R}_{180}$	$\mathbf{R}_{90}$：$\{\sigma_1, \sigma_7\}$; $\mathbf{R}_{180}$：$\{\sigma_1\}$	対	10	85.7	86.9	34
参考 (e10b)	$\mathbf{R}_{90}$, $\mathbf{R}_{180}$	$\mathbf{R}_{90}$：$\{\sigma_1, \sigma_6\}$; $\mathbf{R}_{180}$：$\{\sigma_1\}$	対	10	85.7	87.5	36
参考 (e10c)	$\mathbf{R}_{90}$, $\mathbf{R}_{180}$, $\mathbf{R}_{270}$	$\mathbf{R}_{90}$：$\{\sigma_1\}$; $\mathbf{R}_{180}$：$\{\sigma_1\}$; $\mathbf{R}_{270}$：$\{\sigma_6\}$	対	10	85.7	87.5	37
参考 (e8)	$\mathbf{R}_{90}$, $\mathbf{R}_{180}$	$\mathbf{R}_{90}$：$\{\sigma_6\}$; $\mathbf{R}_{180}$：$\{\sigma_1\}$	対	8	84.1	86.4	34
参考 (e6)	$\mathbf{R}_{90}$, $\mathbf{R}_{180}$	$\mathbf{R}_{90}$：$\{\sigma_1\}$; $\mathbf{R}_{180}$：$\{\sigma_1\}$	対	6	82.2	82.3	30
参考 (e4)	$\mathbf{R}_{90}$	$\mathbf{R}_{90}$：$\{\sigma_1\}$	対	4	81.6	81.7	27
Ablation(c1)	$\mathbf{R}_{180}$	1 つおき (奇)	対	20	82.1	85.6	33
Ablation(c2)	$\mathbf{R}_{180}$	1 つおき (偶)	対	20	80.5	84.9	33
Ablation(c3)	$\mathbf{R}_{90}$	1 つおき (奇)	対	20	83.9	85.4	36
Ablation(c4)	$\mathbf{R}_{90}$	1 つおき (偶)	対	20	82.7	84.4	38
Ablation(c5)	$\mathbf{R}_{90}$, $\mathbf{R}_{180}$	$\{\sigma_1, \sigma_5, \sigma_9\}$	対	18	83.7	85.7	35
Ablation(c6)	$\mathbf{R}_{90}$, $\mathbf{R}_{180}$	$\{\sigma_2, \sigma_6, \sigma_{10}\}$	対	18	82.9	84.8	35
Ablation(c7)	$\mathbf{R}_{180}$	10 点すべて	単	20	81.1	85.2	34
Ablation(c8)	$\mathbf{R}_{90}$	10 点すべて	単	20	83.1	84.8	39
Ablation(c9)	$\mathbf{R}_{90}$, $\mathbf{R}_{180}$	1 つおき (奇)	単	15	83.7	85.6	36
Ablation(c10)	$\mathbf{R}_{90}$, $\mathbf{R}_{180}$	1 つおき (偶)	単	15	82.4	84.5	34
Ablation(c11)	$\mathbf{R}_{90}$, $\mathbf{R}_{180}$, $\mathbf{R}_{270}$	1 つおき (奇)	単	20	83.6	85.5	36
Ablation(c12)	$\mathbf{R}_{90}$, $\mathbf{R}_{180}$, $\mathbf{R}_{270}$	1 つおき (偶)	単	20	82.5	84.5	34
Ablation(r60)	$\mathbf{R}_{90}$, $\mathbf{R}_{180}$	10 点すべて	対	60	84.4	86.6	43
Ablation(r80)	$\mathbf{R}_{90}$, $\mathbf{R}_{180}$, $\mathbf{R}_{270}$	10 点すべて	対	80	84.1	86.3	44
Ablation(dev)	$\mathbf{R}_{180}$	$\{\sigma_1, \sigma_3, \sigma_4, \sigma_6, \sigma_8\}$	対	20	–	86.4	35

84.4–85.7%の範囲にあり, c3 は 85.4%(36 組) で, Euphonium(86.9%, 34 組) に平均で及ばない (並ぶか上回る組の数はやや多い). $\mathbf{R}_{180}$ だけを用いる候補 (c1, c2, c7) は SVHN を分布内とするときに選択用データで大きく下がる (c1 で 85.7%. c3 は 98.9%). 数字は 180° 回しても別の数字 (6 と 9) か同じ数字 (0, 8) に見えるが, 90° 回すと数字に見えないためと考えられる. Euphonium も $\mathbf{R}_{180}$ の原子をもつため, SVHN では c3 より下がり (選択用データで 96.2%対 98.9%, 主評価で 98.0%対 99.6%), CIFAR-100 では細かいスケール σ_1 の原子により上がる (主評価で 72.8%対 61.7%).10 スケールすべてを用いる r60(60 回) と r80(80 回) は主評価 86.6%, 86.3%で, 順伝播を 6–8 倍にしても Euphonium と同程度である. 逆に予算を絞ると, 選択用データでの最良は 8 回 (e8) で主評価 86.4%, 6 回 (e6) で 82.3%, 4 回 (e4) で 81.7%である. ノイズを $+\vec{\varepsilon}$ だけにした単一ノイズの候補 (別の実行. 対と共通の画像で評価) では, 5 回以内の最良は $\mathbf{R}_{90}$：σ_1, σ_6；$\mathbf{R}_{180}$：σ_1(5 回) で選択用データ 84.7%, 主評価 86.4%(30 組) であり, 同じ画像での Euphonium(85.7%, 86.9%) に選択用データで 1 ポイント, 主評価で 0.5 ポイント及ばない (符号反転対の効果は A.5).

A.5　ノイズの共有の効果

表 A4 は, 推定の方法だけを変えて Euphonium を計算したものである. 画像と回転画像に独立なノイ

表 A4 推定の方法を変えたときの Euphonium の平均 AUROC[%. CIFAR-10 を分布内とする 12 組 (上下反転と合成画像を含む). 最終評価用のすべての画像を用いるため, 本文の表 (9 集合, 共通の部分集合) とは値が異なる]. 乱数による揺らぎの標準偏差は 0.6 ポイント.

推定の方法	平均 AUROC
共有ノイズ, 符号反転対 (本文の設定)	92.2
画像と回転画像に独立なノイズ	86.5
共有ノイズ, 符号反転対なし	88.9
共有ノイズ, テスト画像ごとに別のノイズ	91.5

表 A5 共有ノイズは差からノイズの大きさの揺らぎを取り除く (CIFAR-10 のモデル, $\mathbf{T} = \mathbf{R}_{90}$, 最終評価用の分布内の画像 5000 枚, ノイズの乱数 3 通り. 二乗誤差は $D = 3072$ 個の画素値について和をとる). スケールごとに, $e_k(\vec{x})$ の平均, 差 $e_k(\mathbf{R}_{90}\vec{x}) - e_k(\vec{x})$ の平均, 画像平均した $e_k(\vec{x})$ の乱数の間での最大のずれ ($|\vec{\varepsilon}|^2$ の揺らぎ. $\sqrt{2D} = 78$), 画像平均した共有ノイズの差の最大のずれ, 独立なノイズを用いたときの差の画像ごとの分散と共有ノイズでの差の分散を示す.

σ_k	$\bar{e}_k(\vec{x})$	差の平均	$e_k(\vec{x})$ のずれ	差のずれ	分散 (独立)	分散 (共有)
0.01	1585	52.7	34.7	4.1	2275	1613
0.0171	1241	49.2	72.0	3.6	3233	1388
0.0293	1068	38.3	48.5	1.7	1686	925
0.0501	818	29.8	8.6	0.6	1209	522
0.0858	621	30.2	13.3	1.9	808	528
0.147	433	28.3	10.7	2.3	675	518
0.251	275	25.3	8.1	0.9	639	457
0.43	184	22.8	9.0	1.8	542	417
0.736	114	15.5	1.8	1.0	258	243
1.26	65	9.1	3.0	0.2	123	106

ズを用いると平均 AUROC は 92.2%から 86.5%に下がり, 符号反転対を除くと 88.9%に下がる. テスト画像ごとに別のノイズを用いても 91.5%と変わらない. 表 A5 は, 共有ノイズが差から揺らぎを取り除く様子を直接測定したものである. 細かいスケールでは $e_k(\vec{x})$ の画像平均の乱数によるずれが最大 72.0 に達し, 差の平均 (最大 52.7) を上回りうるが, 共有ノイズでの差のずれはどのスケールでも 4.1 以下である. 画像ごとの差の分散も共有ノイズのほうが小さい (右の 2 列).

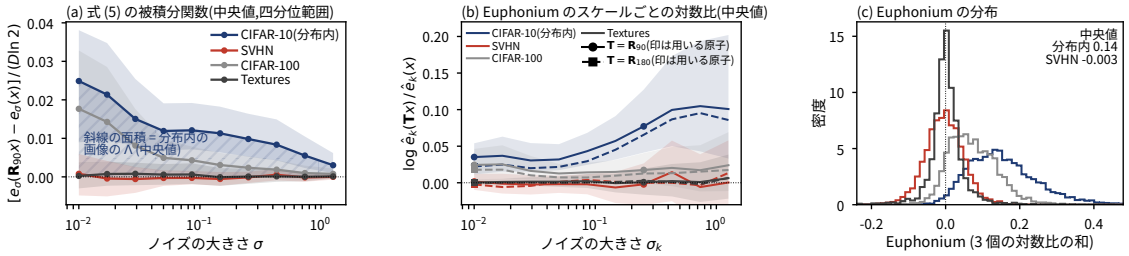


図 A1 被積分関数と向きの統計量 Euphonium(CIFAR-10 のモデル, 最終評価用の画像). (a) 式 (11) の被積分関数 $[e_\sigma(\mathbf{R}_{90}\vec{x}) - e_\sigma(\vec{x})]/(D\ln 2)$ の中央値と 25–75%の範囲 (10 スケール). 分布内の CIFAR-10 ではすべてのスケールで正であり, 単純な SVHN と複雑な Textures ではどちらも 0 に近い. (b) スケールごとの対数比 $\log \hat{e}_k(\mathbf{T}\vec{x})/\hat{e}_k(\vec{x})$ の中央値 (10 スケール. 実線：$\mathbf{T} = \mathbf{R}_{90}$, 帯は 25–75%の範囲. 破線：$\mathbf{T} = \mathbf{R}_{180}$) と, Euphonium の用いる 3 つの原子 (印). 分布内の画像ではどちらの回転でもすべてのスケールで正であり, 粗いスケールほど大きい. (c) 3 つの対数比の和 Euphonium の分布. 分布内の画像の 98.1%で Eu > 0 である.

A.6 符号か大きさか (全列)

表 A6 表 3 の全列. 自然画像の分布外集合での平均 AUROC(%). $\ell_{\mathbf{T},k} = \log \hat{e}_k(\mathbf{T}\vec{x})/\hat{e}_k(\vec{x})$ は原子 $(\mathbf{T}, k) \in \mathcal{A}$ の対数比. Euphonium, $-|\mathrm{Eu}|$, $-\sum|\ell_{\mathbf{T},k}|$, $-|\mathrm{Eu} - \mathrm{med}|$ は同じ 10 回の評価から. 予測差 (GEPC) は GEPC の実行の $\mathbf{R}_{90}$ の予測差 $\|\vec{a} - \vec{b}\|^2/\|\vec{b}\|^2$ を「大きいほど分布外」と読んだもの, GEPC は 6 変換を用いる本来の GEPC(表 2). 最後の列は参考：Euphonium の分布内の開発用画像の中央値 med からのずれ (両側の典型性) で, 反転する組は補えるが他で下がる.

分布内	Euphonium	$-\lvert\mathrm{Eu}\rvert$	$-\sum\lvert\ell_{\mathbf{T},k}\rvert$	予測差 (GEPC)	GEPC	$-\lvert\mathrm{Eu} - \mathrm{med}\rvert$
CIFAR-10	91.2	9.9	10.9	28.8	50.1	78.2
SVHN	98.0	5.4	5.8	96.0	91.8	85.0
CelebA	100.0	0.0	0.0	1.3	98.7	100.0
CIFAR-100	72.8	29.3	26.9	47.1	55.5	60.4
ImageNet-64	60.5	39.0	39.7	52.7	49.1	58.9
FashionMNIST	98.9	4.0	5.9	13.7	84.0	92.7
平均	86.9	14.6	14.9	39.9	71.6	79.2

表 A6 に表 3 の全列を示す. 同じ 10 回の評価から符号を捨てた $-|\mathrm{Eu}|$ と $-\sum|\ell_{\mathbf{T},k}|$ は, 分布内のほうが回転に対する不整合が大きいために 6 つの分布内すべてで 50%を下回る. GEPC の実行から取り出した予測差のノルムは分布内によって向きが変わる (CIFAR-10 で 28.8%, SVHN で 96.0%). Euphonium の中央値からのずれ (両側) は反転する組を補う (CIFAR-100 に対する CIFAR-10 で Euphonium の 24.4%に対し 65.5%) が, CIFAR-100 の 9 集合の平均では 60.4%と Euphonium の 72.8%より下がり, 向きの強い分布内でも Euphonium より下がる.

A.7 分布内データセットの向きの強さと反転

反転が起きたのは, 分布内の画像での Euphonium の平均が小さい (向きの弱い)CIFAR-100 と ImageNet-64 に限られ, どちらも分布外のほうが強い向きをもつ組 (CIFAR-10, CelebA) である. 反転は厳密な比 Λ_{90} でも同じ組で起こるため, 推定の誤差によるものではない. 表 A7 の交差評価に加え, 同じ構成と学習手順の自前の U-Net を学習量を変えて評価した (分布内の画像のみ. $\mathbf{R}_{180}$, 5 スケール $\{0.01, 0.029, 0.05, 0.147, 0.43\}$ の対数比の和). CIFAR-10 では分布内の $\overline{\mathrm{Eu}}$ が 0.125M 枚の 0.031 から 32M 枚の 0.173 まで学習とともに単調に増え, 一般物体の画像である Tiny-ImageNet(32×32) を学習データとするモデルでも 0.125M 枚の 0.013 から 32M 枚の 0.033 へとゆるやかに増える. 向きの強さは学習とともに増えるが, 同じ学習量での差はデータの側にある (8M 枚で 0.024 対 0.128, 32M 枚で 0.033 対 0.173). なお, 狭い領域のモデル (SVHN,

表 A7 向きの弱さはデータの性質である：モデルと画像の交差評価. CIFAR-10 のモデルと CIFAR-100 のモデル (同じ DDPM++の構成) で, CIFAR-10 と CIFAR-100 の画像 (本文の表と同じ最終評価用の画像) の Euphonium の平均 (括弧は平均を標準偏差で割った値) と厳密な Λ_{90} の平均 (bits/dim). 行 (モデル) の差はなく, 列 (画像) の差だけがある.

	CIFAR-10 の画像		CIFAR-100 の画像	
	$\overline{\mathrm{Eu}}$	$\bar{\Lambda}_{90}$	$\overline{\mathrm{Eu}}$	$\bar{\Lambda}_{90}$
CIFAR-10 のモデル	0.16 (1.31)	0.099	0.07 (1.09)	0.053
CIFAR-100 のモデル	0.17 (1.38)	0.104	0.08 (1.19)	0.058

表 A8 分布内の画像での Euphonium の平均 ± 標準偏差 [式 (6) の向きの強さの目安], 反転した組 (自然画像と上下反転の集合のうち Euphonium の AUROC が 49%未満) の数, Euphonium の AUROC が最も低い分布外集合とそこでの Euphonium と厳密な比 Λ_{90} の AUROC(%).

分布内	$\overline{\mathrm{Eu}}$	反転	最も低い組	Euphonium	Λ_{90}(ODE)
CIFAR-10	0.16 ± 0.12	0/10	CIFAR-100	76.0	71.1
SVHN	0.17 ± 0.08	0/10	上下反転	85.4	–
CelebA	0.66 ± 0.15	0/10	Textures	99.9	–
CIFAR-100	0.08 ± 0.07	1/10	CIFAR-10	24.4	29.4
ImageNet-64	0.04 ± 0.03	1/8	CelebA	6.6	25.2
FashionMNIST	0.38 ± 0.20	0/5	上下反転	92.5	–

CelebA) は自分の領域以外の画像の向きをほとんど知らず (他の 9 集合で $|\overline{\mathrm{Eu}}| \leq 0.03$), 一般物体の 2 つのモデル (CIFAR-10, CIFAR-100) は 10 集合のそれぞれに互いにほぼ同じ $\overline{\mathrm{Eu}}$ を与える (差は 0.02 以内).

A.8 スケールごとの証拠と, Euphonium と厳密な比の対応

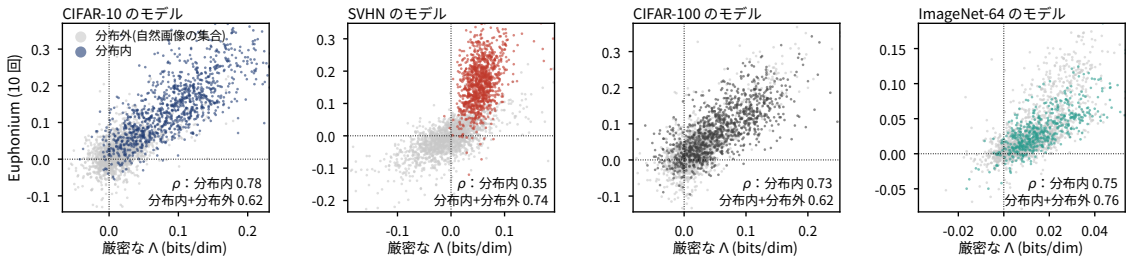


図 A2 検知に用いる Euphonium(10 回. 縦軸) と PF-ODE による厳密な Λ_{90}(横軸, bits/dim) の画像ごとの対応. 厳密な比を計算した 4 つの分布内データセットについて, 分布内の画像 (色) と自然画像の分布外集合 (灰色) を示す. ρ は順位相関 (分布内の画像のみ, および分布内と分布外を合わせたもの). Euphonium は $\mathbf{R}_{180}$ の原子を含み, 重みづけも Λ_{90} と異なる. SVHN では Λ が小さくても Euphonium が大きい (証拠が粗いスケールにあり, Λ はそれを軽く, Euphonium は等しく重みづける). SVHN で 10 スケールの推定量の順位相関も低い (0.61) のは, 分布内の Λ の広がりが小さい (標準偏差 0.024 bits/dim. CIFAR-10 は 0.064) ためと考えられる.

表 A9 は図 3(b) の数値である. CIFAR-10 では σ_1–σ_9 の対数比が 81–86%でほぼ平坦であり, σ_{11}–σ_{13} では 70.0, 66.5, 62.2%と下がる. 13 スケールの和は 10 スケールの和より 91.0 から 87.2%に下がる. SVHN では粗いスケール (σ_7–σ_{10}) の証拠が強く, CIFAR-100 では証拠が細かいスケール (σ_1–σ_3 で 70%以上) にほぼ限られる. 厳密な比は式 (15) の重み $\hat{e}_k$ によって細かいスケールを重く数えるため, SVHN では Euphonium より低く, CIFAR-100 では $\mathbf{R}_{90}$ の 10 スケールの等重みの和「10」(60.2%) より高い. Euphonium は CIFAR-100 の証拠を σ_1 の原子で拾うため, 厳密な比に並ぶ (72.8%対 73.0%). 対数比を差の形にすると値は厳密な比の側に動き (「差 10」は SVHN で 78.2%, CIFAR-100 で 72.1%. 対数比の「10」は 99.8%, 60.2%, 厳密な比は 89.6%, 73.0%), 対数比との違いが重みづけによることを示す.

表 A9 スケールごとの対数比 $\log \hat{e}_k(\mathbf{T}\vec{x})/\hat{e}_k(\vec{x})$ の AUROC(%. 自然画像の分布外集合の平均. 本文の表と同じ最終評価用の画像) と, 原子の集合を変えた和の AUROC. 分布内ごとに上の行が $\mathbf{T} = \mathbf{R}_{90}$, 下の行 $[(\mathbf{R}_{180})]$ が $\mathbf{T} = \mathbf{R}_{180}$ で, 太字が Euphonium の用いる原子. 「Eu」は Euphonium(10 回),「10」は $\mathbf{R}_{90}$ の σ_1–σ_{10} の和 (40 回),「13」は $\sigma_{13} = 6.31$ までの和. 「差 Eu」「差 10」は対数比ではなく誤差の差 $\hat{e}_k(\mathbf{T}\vec{x}) - \hat{e}_k(\vec{x})$ を同じ原子についてそのまま足した形 [式 (15) の第 1 の近似. 差 10 が図 3(a) で厳密な比と照合した推定量]. Λ_{90} は PF-ODE の厳密な比.

分布内	σ_1	σ_2	σ_3	σ_4	σ_5	σ_6	σ_7	σ_8	σ_9	σ_{10}	σ_{11}	σ_{12}	σ_{13}	Eu	10	13	差 Eu	差 10	Λ_{90}
	0.01	0.017	0.029	0.05	0.086	0.147	0.251	0.43	0.736	1.26	2.15	3.69	6.31						
CIFAR-10	**83.3**	82.9	83.4	83.4	85.0	86.0	**85.0**	84.8	81.6	76.2	70.0	66.5	62.2	91.2	91.0	87.2	90.1	91.8	90.2
CIFAR-10($\mathbf{R}_{180}$)	**83.7**	85.7	85.5	84.8	85.6	87.3	86.3	86.1	83.5	78.0	69.0	65.0	56.8						
SVHN	**82.6**	71.4	78.3	86.4	90.8	96.3	**98.1**	99.4	99.6	98.8	92.8	95.2	79.7	98.0	99.8	99.7	73.5	78.2	89.6
SVHN($\mathbf{R}_{180}$)	**59.5**	57.4	68.6	75.8	81.9	84.3	94.7	94.1	90.6	88.9	85.9	73.3	31.0						
CelebA	**99.9**	99.9	99.8	99.9	99.9	99.9	**99.8**	99.9	99.8	99.5	99.7	98.7	98.8	100.0	100.0	100.0	100.0	100.0	–
CelebA($\mathbf{R}_{180}$)	**100.0**	100.0	100.0	99.9	99.9	99.9	99.8	99.8	99.6	99.1	99.3	97.5	95.2						
CIFAR-100	**76.5**	74.4	70.2	59.8	52.8	50.9	**49.1**	47.6	47.6	48.0	51.6	54.8	56.1	72.8	60.2	59.7	79.6	72.1	73.0
CIFAR-100($\mathbf{R}_{180}$)	**79.8**	78.3	72.3	60.0	51.5	51.0	47.4	48.7	48.8	49.9	49.7	52.4	51.6						
ImageNet-64	**63.2**	67.8	68.7	63.5	61.7	61.8	**59.5**	59.5	58.0	56.5	52.7	51.4	51.7	60.5	61.7	59.3	63.8	62.9	62.6
ImageNet-64($\mathbf{R}_{180}$)	**63.9**	68.8	69.8	64.3	62.3	62.7	62.0	62.3	59.4	55.2	50.6	49.8	46.6						
FashionMNIST	**84.4**	89.6	91.6	96.3	96.2	97.9	**98.7**	98.8	97.9	97.7	96.6	89.9	81.1	98.9	99.7	99.4	98.9	99.8	–
FashionMNIST($\mathbf{R}_{180}$)	**75.3**	78.5	84.8	92.2	92.6	95.6	96.5	97.4	97.1	97.7	96.2	89.8	66.9						

A.9 全結果

表 A10 と表 A11 に全 63 組の結果を示す. Euphonium は 34 組で 8 つの比較手法の最良に並ぶか上回り (0.05 ポイント以内を同点), 1 ポイント以内を同点とみなせば 38 組である. 下回った組の多くは, 尤度だけで 99%に達する SVHN を分布内とする組 (11 組すべて. Euphonium は 98.0%で, 比較手法の最良は 99%を超える) と, 向きの弱い CIFAR-100 と ImageNet-64 を分布内とする組 (13 組) であり, 残りは CIFAR-10 に対する SVHN と, CIFAR-10・FashionMNIST に対する合成画像 (一様ノイズ・定数画像) である. 上下反転した分布内の画像 (内容は分布内と同じで向きだけが異なる) は, Euphonium ではすべての分布内データセットで 78.9–100.0%で検知でき, 比較手法の最良 (52.8–99.9%) に 6 つすべてで並ぶか上回る. これは Euphonium が向きそのものを手がかりにしていることの直接の確認である.

表 A10 全 63 組の AUROC(%)(1/2：CIFAR-10, SVHN, CelebA を分布内とする組). 8 つの比較手法, Ours：Euphonium($\mathbf{R}_{90}$ は σ_1, σ_7；$\mathbf{R}_{180}$ は σ_1. 10 回), および 2 つの Ablation：Eu_{10}($\mathbf{R}_{90}$ の 10 スケール σ_1–σ_{10} の対数比の和, 40 回) と厳密な Λ_{90}(PF-ODE, 512 回). †：8 つの比較手法の中での最良 (SOTA). **水色の太字**：Ours が比較手法の最良に並ぶか上回る組 (BEST. 2 つの表で 34/63 組). 下線：Ours が比較手法の最良にだけ下回る組 (2 位. 8 組). Ablation には印をつけない. PF-ODE を用いる手法は合成画像の集合では計算していない (–).

分布内	分布外	NLL	IC (PNG)	IC (J2K)	TT	MSMA 型	DiffPath	GEPC	EigenScore	Euphonium (Ours)	Eu_{10} (Ablation)	Λ_{90} (Ablation, ODE)
CIFAR-10	CIFAR-100	50.2	55.7	54.4	54.7	54.5	60.3	49.7	76.1†	**76.0**	84.8	71.1
	SVHN	12.5	81.7	96.0	73.6	91.1	99.4†	84.7	66.8	94.9	96.4	95.9
	CelebA	61.3	65.8	67.7†	39.9	43.7	39.4	28.9	61.4	**91.7**	85.4	94.8
	Textures	62.3	74.7	74.1	66.2	90.1†	85.3	66.0	72.1	**94.8**	95.3	94.6
	Tiny-ImageNet	49.1	48.6	45.9	47.4	71.5	77.4†	50.9	76.9	**93.8**	92.7	93.5
	LSUN	72.1	83.7†	77.8	61.6	48.4	62.4	35.0	83.6	**92.2**	91.2	90.3
	ImageNet	58.6	76.7	72.0	59.0	59.0	73.6	47.2	79.3†	**93.5**	92.7	91.8
	ImageNet32	76.9	83.0	74.2	73.7	70.4	84.3†	47.2	78.2	**92.4**	91.1	89.9
	Places365	69.7	82.6†	77.4	63.1	52.4	65.3	41.1	80.9	**91.6**	89.3	89.7
	上下反転	52.7	53.7	53.5	50.7	52.3	54.9	45.2	78.9†	**90.8**	89.7	–
	一様ノイズ	–	–	–	–	100.0†	100.0†	60.6	60.5	97.8	–	–
	定数画像	–	–	–	–	100.0†	99.3	95.6	25.3	91.9	–	–
SVHN	CIFAR-10	98.9	87.1	64.4	98.6	98.5	99.1†	92.3	88.4	98.0	99.9	88.1
	CIFAR-100	98.5	89.4	68.7	97.7	98.4	99.2†	92.2	84.6	97.9	99.8	86.8
	CelebA	99.9†	88.4	64.1	99.9†	98.8	99.4	95.2	85.1	97.9	99.9	85.2
	Textures	96.8	95.2	80.9	97.0	99.6†	99.5	80.7	90.2	96.9	99.2	88.2
	Tiny-ImageNet	98.5	81.7	47.5	97.7	97.7	99.2†	93.2	84.7	97.8	99.8	89.6
	LSUN	99.6	98.6	89.7	99.5	99.8	99.9†	95.3	86.7	98.6	99.9	94.3
	ImageNet	98.9	96.9	85.4	98.7	99.2	99.8†	91.9	82.4	98.1	99.8	91.2
	ImageNet32	99.7	99.3	91.7	99.6	99.9	100.0†	91.8	87.5	98.2	99.8	91.2
	Places365	99.1	97.6	86.7	98.8	99.5	99.8†	93.9	85.4	98.5	99.9	91.5
	上下反転	50.9	51.0	51.3	50.5	50.5	51.3	49.2	71.9†	**85.4**	86.2	–
	一様ノイズ	–	–	–	–	100.0†	100.0†	31.3	97.1	99.1	–	–
	定数画像	–	–	–	–	99.9	100.0†	77.7	58.9	99.7	–	–
CelebA	CIFAR-10	82.2	79.2	75.1	83.6	99.5	99.8†	99.1	88.2	**100.0**	100.0	–
	CIFAR-100	78.6	83.6	79.2	84.1	99.5	99.6†	98.7	86.3	**100.0**	100.0	–
	SVHN	83.0	98.8	99.5	80.2	99.9	100.0†	100.0†	78.8	**100.0**	100.0	–
	Textures	75.6	81.8	79.5	86.0	99.9†	99.9†	99.0	76.6	**99.9**	99.9	–
	Tiny-ImageNet	85.0	78.8	71.4	83.1	99.7	99.8†	98.6	88.9	**100.0**	100.0	–
	LSUN	84.9	89.9	82.8	86.5	99.4	100.0†	97.6	90.5	**100.0**	100.0	–
	ImageNet	76.0	88.9	83.9	81.3	99.3	99.7†	98.2	87.5	**100.0**	100.0	–
	ImageNet32	87.8	90.2	80.0	93.4	99.6	99.9†	99.1	88.8	**100.0**	100.0	–
	Places365	81.2	89.0	82.3	85.6	99.6	99.9†	98.3	89.3	**100.0**	100.0	–
	上下反転	80.1	72.7	71.7	69.2	99.6	99.9†	67.3	84.5	**100.0**	99.9	–
	一様ノイズ	–	–	–	–	100.0†	100.0†	100.0†	94.8	**100.0**	–	–
	定数画像	–	–	–	–	100.0†	100.0†	100.0†	3.7	**100.0**	–	–

表 A11 全 63 組の AUROC(%)(2/2：CIFAR-100, ImageNet-64, FashionMNIST を分布内とする組)．列と記法は表 A10 と同じ．

分布内	分布外	NLL	IC (PNG)	IC (J2K)	TT	MSMA 型	DiffPath	GEPC	EigenScore	Euphonium (Ours)	Eu_{10} (Ablation)	Λ_{90} (Ablation, ODE)
CIFAR-100	CIFAR-10	49.8	44.4	45.7	45.2	49.3	42.1	62.4†	23.3	24.4	15.2	29.4
	SVHN	15.3	77.3	94.0	69.9	87.7	97.3†	70.2	34.2	81.5	75.8	85.7
	CelebA	59.8	59.2	61.9†	33.5	41.7	42.3	43.1	29.9	**73.6**	47.9	76.6
	Textures	61.5	71.8	71.3	61.3	86.9†	79.9	63.1	46.4	85.8	79.4	84.4
	Tiny-ImageNet	49.0	42.8	41.9	42.4	67.1	68.1†	59.4	49.8	**80.3**	69.2	79.4
	LSUN	70.4	79.1†	72.6	55.5	41.6	49.1	48.9	61.3	77.2	63.6	75.1
	ImageNet	57.7	72.1†	67.5	53.7	52.3	63.8	49.2	53.7	**79.4**	67.4	77.5
	ImageNet32	75.5	79.0†	69.4	68.4	59.5	72.5	53.9	51.7	77.7	63.7	74.7
	Places365	68.3	78.4†	72.8	57.4	45.4	53.3	49.6	53.8	74.8	59.6	74.3
	上下反転	51.5	52.4	52.1	50.3	51.2	52.8†	47.7	52.2	**78.9**	67.8	–
	一様ノイズ	–	–	–	–	100.0†	100.0†	37.3	20.2	90.0	–	–
	定数画像	–	–	–	–	100.0†	99.5	90.6	10.8	87.1	–	–
ImageNet-64	SSB-hard	53.4	50.6	48.3	52.2	56.9†	50.2	44.6	49.6	54.8	55.2	55.3
	NINCO	55.0	58.3	53.6	59.3†	56.3	58.4	50.4	46.1	**72.3**	73.6	73.0
	iNaturalist	85.4†	65.9	63.4	72.9	38.5	59.3	44.2	42.7	84.1	86.9	79.3
	Textures	52.4	48.4	46.3	54.5	81.5†	69.5	61.9	48.2	80.4	82.1	82.6
	OpenImage-O	60.9†	60.6	56.7	59.0	53.5	57.1	55.8	48.9	**73.5**	76.2	72.7
	Places365	52.1	49.3	32.3	48.9	74.3†	53.5	48.0	60.1	52.0	52.8	49.9
	CelebA	23.6	15.5	28.5	54.7	76.0†	39.0	38.9	13.5	6.6	4.7	25.2
	上下反転	50.6	51.2	51.1	50.1	48.6	51.4	47.1	66.1†	**86.6**	87.2	–
FashionMNIST	MNIST	10.9	87.4	21.1	79.8	96.5†	71.2	91.8	93.9	**99.1**	99.9	–
	KMNIST	46.3	90.1	34.0	44.8	95.1	75.4	82.0	97.9†	**99.2**	99.8	–
	Omniglot	10.5	77.8	52.1	80.0	96.6†	84.7	94.2	93.9	**98.5**	99.6	–
	notMNIST	64.6	93.8	52.8	44.0	95.2†	94.0	68.1	88.1	**98.5**	99.5	–
	上下反転	53.1	60.5	58.5	51.3	76.9	64.6	49.2	91.4†	**92.5**	94.3	–
	一様ノイズ	–	–	–	–	98.6	100.0†	100.0†	89.0	99.6	–	–
	定数画像	–	–	–	–	88.5	100.0†	97.4	84.7	99.5	–	–